美国航班延误多源数据血缘图（成员2：清洗与融合）

处理路径：四个独立来源 → Raw → Cleaned → Integrated ｜ 关联维度：地点（机场代码/站点/坐标） + 时间（本地计划起飞→UTC）

图例：实线=实际数据流　虚线=回退/接口路径（未触发或仅映射）

S01 主要 | BTS 美国交通统计局
Reporting Carrier On-Time Performance (1987–present)
2024 全年官方 PREZIP 月度 ZIP × 12
关联字段：Origin/Dest·CRSDepTime·AirportID

S02 主要 | NOAA / NCEI Global Hourly (ISD)
2024 年逐站 CSV + isd-history.csv
正式 346 站（SGU 试采集另存、不计入）
关联字段：STATION·DATE（按 UTC 解释）

S03 辅助 | OurAirports 机场资料快照
airports.csv 快照 86,293 条（US 32,697）
iata_code / ident / gps_code / 经纬度
Public Domain；不保证实时性

S04 辅助 | U.S. Census Bureau 州界
cb_2024_us_state_500k.zip（1:500,000）
56 个州及州级等同地区 Polygon
PRJ：NAD83 / GRS 1980

data/raw/BTS/
解压后 12 个月度 CSV
原始 7,079,061 行 · 3.20 GB
（外层年度 ZIP 为本地汇集，非官方年度产品）

data/raw/NOAA/2024/*.csv
正式 346 站逐文件 CSV
4,529,560 条观测 · 2.52 GB
含 SOD/SOM 等多报告类型原始记录

data/raw/OurAirports/airports.csv
86,293 行快照
SHA-256 已存档（metadata/ourairports_inventory.json）

回退路径（348/348 未触发）

data/raw/Census/cb_2024_us_state_500k.zip
ZIP CRC 通过 · 56 条属性
SHP / DBF / PRJ / SHX 齐备

cb SHP (NAD83)

01_clean_bts.py（--mode sample / full）
逐月读取 12 个月 CSV、统一字段口径
标记 Cancelled=96,315 / Diverted=17,499
到达缺失 97,854；ArrDel15 不一致 = 0
仅 2024-08 剔除 1 行缺键（航班号缺失）

02_verify_sample.py → 02_clean_noaa.py full
先 LAX/ORD/JFK 样本逐条对 METAR 原文
按 ISD 文档解析 温/露/压/风/能见/降水
仅保留 FM-15 / FM-16，保留原始质量码
VIS 码值直接=米（不 ×10）；precip 缺测≠无雨

03_airport_timezones.py
坐标优先级：mapping_reviewed → OurAirports 回退
实际 348/348 全部来自 mapping_reviewed
timezonefinder(lat,lon) → IANA 时区
★ OurAirports 直接读坐标：未触发（潜在回退源）

03_state_check.py（空间核验）
解压 Census SHP → shapely STRtree 索引
机场 Point 逐面 point-in-polygon
州界 NAD83 vs 机场坐标 WGS84
500k 比例尺下同按十进制度近似（未投影转换）

复核坐标 348/348

metadata/airport_station_mapping_reviewed.csv（成员1交付的 348 行修订映射）
airport_code ⇆ station_id 映射 + 复核坐标（lat/lon）；含 PBI 别名核验、SGU 位置冲突、XWA 未匹配等例外
键：airport_code / bts_airport_id；坐标经 OurAirports 身份核对后人工修订（上游追溯见 data_sources.md）

03_finalize.py：时区/州界汇总 + 日志
→ airport_timezone_stats.json（金标准 5 机场全 PASS）

州界核验结果

data/cleaned/bts_flights_2024.parquet
7,079,060 行 × 20 列（原始 7,079,061→-1）
sched_dep_local：本地计划起飞时刻
附 bts_cleaning_log.csv / bts_clean_stats.json

data/cleaned/noaa_obs_2024.parquet
3,905,968 行 × 19 列（4,529,560→-623,592）
FM-15 3,204,352 / FM-16 701,616 · 346 站
obs_utc + 各要素质量码；附 noaa_clean_stats.json

data/cleaned/airport_timezones.csv
348 机场 · 22 个唯一 IANA 时区
coord_source=mapping_reviewed（348）
tz_method=timezonefinder（348）

坐标接力

data/cleaned/airport_state_check.csv
state_consistent=1：345 机场
na：3 个 TT 领地（GUM/PPG/SPN）
polygon_state：机场落入的 Census 州面

bts_flights（左表）

airport_code ⇆ station_id

noaa_obs（右表）

tz IANA

polygon_state

04_fusion_weather.py —— 航班 × 天气融合（一行一班；读入全部 Cleaned 产物 + mapping_reviewed + 正式346站清单）
关联键① 地点：flights.origin(airport_code) ──map──⟐ station_id（经 mapping_reviewed）；同时带入 origin_tz_iana、origin_polygon_state；XWA=无站、SGU=不在346清单
关联键② 时间：sched_dep_local ──tz_localize(origin_tz_iana, ambiguous=False；含夏令时、CRSDepTime=2400 跨日按次日00:00)──⟐ dep_utc（UTC）
关联键③ 匹配：obs 先按 (station_id, obs_utc) 去重、同刻 FM-15 优先（3,905,968 → 3,898,753）；再 merge_asof(by=station_id, backward, obs_utc ≤ dep_utc)，窗口 ≤ 90 分钟
空间核验：机场 lat·lon ∩ Census polygon → polygon_state；NAD83/WGS84 同按十进制度近似；输出 weather_gap_minutes 与 weather_match_within_60 标记

data/integrated/flights_weather_2024.parquet —— 一行一班主表：7,079,060 行 × 44 列（flight_id 唯一；行数与 BTS 清洗表完全一致）
weather_match_status：matched 7,055,161（99.662%） ｜ 60 分钟窗口 7,047,642（99.556%） ｜ gap 中位 25 分钟
陈旧观测 no_obs_within_90 18,904（>90min，中位约194min，建模前应过滤） ｜ 无站 XWA 1,972 班 ｜ SGU 3,023 班 ｜ WYS 仅 2024-04-29~11-06 有观测，覆盖外自然未匹配、不补造天气
附 data/integrated/fusion_stats.json（匹配率/gap分布/质量码分布/州界一致性）与 flights_weather_2024_sample.csv（前 2 万行，仅查看）

质量检查与证据（随图交付）
cleaning/logs/ 8 份核验日志：bts_sample_check / bts_final_check / noaa_sample_verify / noaa_format_notes / noaa_full_run / noaa_final_check / timezone_state_verify / fusion_check
docs/quality_report.md（10 项口径）· docs/field_dictionary.md（5 张表逐列定义）· metadata/member2_deliverable_checksums.sha256（交付件 SHA-256）
硬校验：flight_id 唯一 · 融合前后行数不变 7,079,060 · dep_utc NaT=0 · 州界 345 一致/3 TT 领地编码差异（非位置错误）